人工智能与机器学习基础
HW2：神经网络与反向传播

中国科学技术大学

2026 年秋季学期　学生版

截止时间：2026 年 11 月 23 日 06:00

个人完成，预计 4–6 小时，满分 100 分。共五道大题、15 个小问；各大题独立，符号与假设以本题为准。第一题简要文字作答，第二至第五题只需给出所要求的计算或推导。题中已给公式可直接使用，无需另证。

允许使用 AI 辅助，但须在文末说明使用方式，并提供至少一项独立核验记录，例如代入特例、核对维度或使用有限差分检查梯度；未使用 AI 的同学同样给出一项自检。最终答案应能由本人独立解释。

提交要求

按题号作答，保留必要步骤；提交一个 PDF，命名为学号-姓名-HW2.pdf，上传至 Blackboard（bb.ustc.edu.cn）。截止时间为 2026 年 11 月 23 日 06:00。如有疑问，请通过课程仓库 Issues提问，注明 HW2 和题号，不要公开个人信息或完整答案。

1　训练现象与实验判断　[12 分]

本题均考虑使用梯度下降训练的前馈神经网络。各小问互不依赖。

（1）（4 分）隐藏层含多个神经元，它们的激活函数相同，输入权重、偏置及通向下一层的对应权重均初始化为相同值。训练中使用相同批次、不引入随机扰动。说明这种初始化可能造成什么问题，并给出一种修正方法。

（2）（4 分）在数据、批次顺序与训练预算固定的实验中，训练损失从开始就大幅振荡，并很快出现非有限数值。一位同学建议先增大正则化强度。给出一种更直接的排查实验，并说明什么观测结果支持“学习率过大”这一解释。

（3）（4 分）某模型的训练损失持续下降，验证损失先下降后持续上升。说明应如何选择用于最终测试的模型，并指出为什么不能根据测试集结果决定停止时刻。

2 Softmax 与交叉熵 [22 分]

考虑一个具有 $K \geq 2$ 个类别的分类模型。列向量 $z \in \mathbb{R}^K$ 为模型输出的分数，$y \in \mathbb{R}^K$ 为 one-hot 标签：真实类别对应分量为 1，其余为 0。定义

$$p_k = \frac{\exp(z_k)}{\sum_{j=1}^{K} \exp(z_j)}, \qquad \ell(z, y) = -\sum_{k=1}^{K} y_k \log p_k.$$

这里 $p = (p_1, \ldots, p_K)^\top$，log 为自然对数，$\mathrm{diag}(p)$ 为以 p 的分量作对角元的矩阵，$\mathbb{1}_K$ 为全 1 列向量。梯度统一记为列向量。

（1）（8 分）推导 $\partial p_k / \partial z_j$，并由此求交叉熵对 z 的梯度 $\nabla_z \ell$。分别写出 $j = k$ 和 $j \neq k$ 的导数，或用等价的统一公式。

（2）（8 分）推导 Hessian 矩阵 $H = \nabla_z^2 \ell$。对任意 $u \in \mathbb{R}^K$，将二次型 $u^\top H u$ 写成非负的加权平方和，并计算 $H\mathbb{1}_K$。

（3）（6 分）取

$$K = 3, \qquad z = (1000, 1000, 999)^\top, \qquad y = (0, 1, 0)^\top.$$

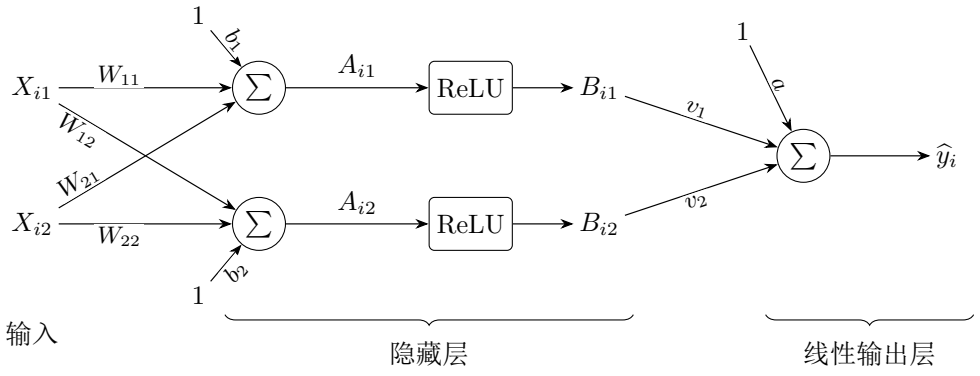
令 $m = \max_j z_j$。通过同时减去 m，写出不含 $\exp(1000)$ 的概率向量和损失表达式，并证明这种变换对任意有限 z 都保持概率不变。数值可保留为含 e^{-1} 的精确形式。

3 两层网络的矩阵反向传播 [26 分]

设正整数 n, d, h 分别为样本数、输入维数和隐藏单元数。样本按行排列，使用一个隐藏层和标量线性输出：

$$X \in \mathbb{R}^{n\times d}, \quad W \in \mathbb{R}^{d\times h}, \quad b, v \in \mathbb{R}^{h}, \quad a \in \mathbb{R}, \quad y \in \mathbb{R}^{n},$$
$$A = XW + \mathbb{1}_n b^{\top}, \quad B = \mathrm{ReLU}(A),$$
$$\widehat{y} = Bv + a\mathbb{1}_n, \qquad L = \frac{1}{2n}\|\widehat{y} - y\|_2^2.$$

其中 $\mathbb{1}_n$ 为全 1 列向量；$\mathrm{ReLU}(t) = \max\{0, t\}$ 逐元素作用。假设 A 的元素均不为零，定义掩码 $M \in \mathbb{R}^{n\times h}$：当 $A_{ij} > 0$ 时 $M_{ij} = 1$，否则为 0。符号 $\odot$（Hadamard 积）表示逐元素乘法，矩阵梯度与对应矩阵形状相同。



图示为 $d = h = 2$ 时第 i 个样本的前向计算，$i = 1, \ldots, n$；各样本共享参数。

（1）（10 分）记 $r = \widehat{y} - y$。从链式法则出发，推导 $\nabla_v L$、$\partial L/\partial a$、$\nabla_W L$ 与 $\nabla_b L$，写出各自形状。

（2）（6 分）取以下小规模实例，计算 A、B、$\widehat{y}$ 和 L：

$$X = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad W = \begin{bmatrix} 1 & -1 \\ 2 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad v = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad a = 0, \quad y = \begin{bmatrix} 0 \\ 2 \end{bmatrix}.$$

（3）（10 分）对第（2）小问的同一组参数，取学习率

$$\eta = 0.1.$$

计算一次反向传播的四个参数梯度，并使用梯度下降同时更新全部参数。写出更新后的 W^+、b^+、v^+ 和 a^+，保留必要的中间步骤。所有梯度均在更新前的参数处计算。

4 ReLU 网络的表示与零梯度 [20 分]

输入为 $x = (x_1, x_2)^\top \in \mathbb{R}^2$，目标是在以下四个点精确输出指定实数：

$$f(0,0) = 0, \quad f(1,0) = 1, \quad f(0,1) = 1, \quad f(1,1) = 0.$$

定义 $\mathrm{ReLU}(t) = \max\{0, t\}$，逐元素作用于向量。只要求这四个点上的函数值，不要求对其他输入满足某种标签规则。

（1）（6 分）证明：不存在实数 $\alpha_1, \alpha_2, \beta$，使仿射函数 $g(x) = \alpha_1 x_1 + \alpha_2 x_2 + \beta$ 满足以上四个等式。

（2）（8 分）构造一个含两个隐藏单元的网络，给出 U, c, v, a 的一组具体取值，并核对四个函数值：

$$f(x) = v^\top \mathrm{ReLU}(Ux + c) + a, \quad U \in \mathbb{R}^{2\times 2}, \quad c, v \in \mathbb{R}^2, \quad a \in \mathbb{R}.$$

可直接使用恒等式 $\mathrm{ReLU}(t) + \mathrm{ReLU}(-t) = |t|$。

（3）（6 分）考虑一个独立的一维回归问题，仅有一个样本 $x = 1, y = 1$，模型和损失为

$$\widehat{y} = v\,\mathrm{ReLU}(wx + b), \qquad L = \frac{1}{2}(\widehat{y} - y)^2, \qquad w, b, v \in \mathbb{R}.$$

在参数 $w = 0, b = -1, v = 1$ 处，计算损失与全部三个参数的一阶导数；再给出一组损失更低的参数。

5 参数缩放与训练过程 [20 分]

设输入 $x \in \mathbb{R}^d$，模型为

$$f_{w,v}(x) = v\,\mathrm{ReLU}(w^\top x), \qquad w \in \mathbb{R}^d \setminus \{0\}, \quad v \in \mathbb{R} \setminus \{0\}.$$

其中 d 为正整数，$\mathrm{ReLU}(t) = \max\{0, t\}$。可直接使用正齐次性质

$$\mathrm{ReLU}(ct) = c\,\mathrm{ReLU}(t), \qquad c > 0.$$

对任意缩放因子 $c > 0$，记 $w_c = cw$、$v_c = v/c$。向量范数为欧氏范数。

（1）（6 分）证明缩放前后对任意输入的预测完全一致。固定 $\lambda > 0$，写出缩放后参数的正则化项

$$R(c) = \frac{\lambda}{2}\big(\|w_c\|_2^2 + v_c^2\big),$$

并给出一组 w, v, c 的具体取值，使预测不变而正则化项发生变化。

（2）（8 分）将 w, v 视为固定，求使 $R(c)$ 最小的 $c > 0$，并求最小值。需说明所求点是全局最小点。

（3）（6 分）本小问不加正则化。给定样本 (x_i, y_i)，其中 $x_i \in \mathbb{R}^d$、$y_i \in \mathbb{R}$，$i = 1, \ldots, n$，n 为正整数，定义

$$L(w, v) = \frac{1}{2n}\sum_{i=1}^{n}\big(f_{w,v}(x_i) - y_i\big)^2.$$

假设全部 $w^\top x_i \neq 0$。记 $G_w = \nabla_w L(w, v)$、$G_v = \partial L(w, v)/\partial v$。在缩放后的点，用同一学习率 $\eta > 0$ 同时更新：

$$w_c^+ = w_c - \eta \nabla_{w_c} L(w_c, v_c), \qquad v_c^+ = v_c - \eta \frac{\partial L(w_c, v_c)}{\partial v_c}.$$

推导梯度随 c 的变化关系，并用 w, v, G_w, G_v, η, c 表示还原后的参数

$$\widetilde{w}^+ = w_c^+/c, \qquad \widetilde{v}^+ = c v_c^+.$$

最后写出 $c = 2$ 时两个梯度项的有效学习率。