人工智能与机器学习基础
HW3：无监督表示、分类几何与模型复杂度

中国科学技术大学

2026 年秋季学期　学生版

截止时间：2026 年 12 月 21 日 06:00

个人完成，满分 100 分。共五道大题、19 个小问；各大题独立，符号与假设以本题为准。给出所要求的计算、推导或构造及必要核验。题内明确给出的公式和事实可直接使用。后续小问可引用题目要求证明的中间结论，即使未完成该结论的证明。

允许使用 AI 辅助，但须在文末说明使用方式，并提供至少一项独立核验记录，例如核对维度、代入特例或用数值计算检验推导；未使用 AI 的同学同样给出一项自检。最终答案应能由本人独立解释。

提交要求

按题号作答，保留必要步骤；提交一个 PDF，命名为学号-姓名-HW3.pdf，上传至 Blackboard（bb.ustc.edu.cn）。截止时间为 2026 年 12 月 21 日 06:00。如有疑问，请通过课程仓库 Issues提问，注明 HW3 和题号，不要公开个人信息或完整答案。

1　K-means 与 PCA：离散划分和连续方向　[20 分]

设 $n \geq 2$、$d \geq 1$ 为整数，样本 $x_i \in \mathbb{R}^d$ 按行组成非零矩阵 $X \in \mathbb{R}^{n\times d}$，并已中心化：

$$X = \begin{bmatrix} x_1^\top \\ \vdots \\ x_n^\top \end{bmatrix}, \qquad \sum_{i=1}^{n} x_i = 0.$$

将样本下标划分为两个非空集合 C_1, C_2，记 $n_k = |C_k|$、$n_1 + n_2 = n$。簇中心 $\mu_1, \mu_2 \in \mathbb{R}^d$，目标为

$$J(C_1, C_2; \mu_1, \mu_2) = \sum_{k=1}^{2} \sum_{i\in C_k} \|x_i - \mu_k\|_2^2.$$

$\|\cdot\|_2$ 为欧氏范数，$\|X\|_F^2 = \sum_i \sum_j X_{ij}^2$；$\mathbb{1}_n$ 为全 1 列向量。记固定划分下对中心最小化后的目标为 $J_*(C_1, C_2)$。

（1）（6 分）对固定的 C_1, C_2，推导最优簇中心 $\bar{x}_k$，并证明

$$J_*(C_1, C_2) = \|X\|_F^2 - n_1\|\bar{x}_1\|_2^2 - n_2\|\bar{x}_2\|_2^2.$$

（2）（5 分）定义 $z \in \mathbb{R}^n$ 为

$$z_i = \begin{cases} \sqrt{\dfrac{n_2}{nn_1}}, & i \in C_1, \\ -\sqrt{\dfrac{n_1}{nn_2}}, & i \in C_2. \end{cases}$$

验证 $z^\top z = 1$、$z^\top \mathbb{1}_n = 0$，并证明

$$J_*(C_1, C_2) = \|X\|_F^2 - z^\top XX^\top z.$$

（3）（5 分）现在不再要求向量来自某个两簇划分，而允许选择任意满足单位长度和零和条件的 $v \in \mathbb{R}^n$。设 $\lambda_1 > 0$ 为 $X^\top X$ 的最大特征值，$u_1 \in \mathbb{R}^d$ 是对应的一个单位特征向量。求

$$B = \min_{\substack{v \in \mathbb{R}^n \\ v^\top v = 1,\ v^\top \mathbb{1}_n = 0}} \left(\|X\|_F^2 - v^\top XX^\top v \right),$$

并用第一主成分得分向量 Xu_1 写出一个达到最小值的 v。证明 $B \le J_*(C_1, C_2)$ 对任意两簇划分成立。

可使用以下线性代数事实：实对称矩阵有正交归一的特征向量基；$XX^\top$ 与 $X^\top X$ 的非零特征值相同。注意：最大特征值不一定为单重。

（4）（4 分）取

$$X = \begin{bmatrix} -2 & 0 \\ -1 & 0 \\ 1 & 0 \\ 2 & 0 \end{bmatrix}.$$

计算第（3）问的下界 B；给出一个具体两簇划分，计算其中心及 J_*；证明任何两簇划分都不能达到 B。无需枚举全部划分，也无需证明你给出的划分是全局最优划分。

2 EM 与 K-means：软分配、极限与退化 [20 分]

设样本为 $x_i \in \mathbb{R}^d$，$i = 1, \dots, n$，分量数为整数 $K \geq 2$，I_d 为单位矩阵。前三问使用等权、共同球形协方差的高斯混合模型：

$$p_\sigma(x; \mu) = \frac{1}{K} \sum_{k=1}^{K} \mathcal{N}(x \mid \mu_k, \sigma^2 I_d), \qquad \mu = (\mu_1, \dots, \mu_K), \quad \mu_k \in \mathbb{R}^d,$$

$$\mathcal{N}(x \mid \mu_k, \sigma^2 I_d) = (2\pi\sigma^2)^{-d/2} \exp\left(-\frac{\|x - \mu_k\|_2^2}{2\sigma^2} \right), \qquad \ell_\sigma(\mu) = \sum_{i=1}^{n} \log p_\sigma(x_i; \mu).$$

log 为自然对数。进行一次 EM 更新时，$\sigma > 0$ 和混合权重固定，只更新均值。第（2）问中的极限，是在数据和中心均固定时比较不同的正数 σ，而非在一次 EM 迭代中更新方差。

（1）（6 分）设隐变量 $h_i \in \{1, \dots, K\}$ 表示第 i 个样本所属分量，且 $P(h_i = k) = 1/K$。用贝叶斯公式推导责任度

$$r_{ik} = P(h_i = k \mid x_i; \mu).$$

固定 E 步得到的 r_{ik}，从以下 M 步目标出发，求每个更新后的均值 μ_k^+：

$$Q(\widetilde{\mu}; r) = \sum_{i=1}^{n} \sum_{k=1}^{K} r_{ik} \log \left[\frac{1}{K} \mathcal{N}(x_i \mid \widetilde{\mu}_k, \sigma^2 I_d) \right].$$

写出求导步骤，并说明本题有限参数、正方差条件下更新式的分母为何为正。

（2）（6 分）固定所有中心，记

$$d_{ik} = \|x_i - \mu_k\|_2^2, \qquad m_i = \min_k d_{ik}, \qquad T_i = \{k : d_{ik} = m_i\}.$$

分别求 $|T_i| = 1$ 和 $|T_i| > 1$ 时 r_{ik} 在 $\sigma \to 0^+$ 时的极限。再定义

$$D_\sigma(\mu) = -2\sigma^2 \sum_{i=1}^{n} \log \left(\sum_{k=1}^{K} \exp\left[-\frac{d_{ik}}{2\sigma^2} \right] \right).$$

它与 $-2\sigma^2 \ell_\sigma(\mu)$ 仅相差一个与中心无关的常数。通过对括号内的指数和作上下界估计，证明

$$\sum_{i=1}^{n} m_i - 2n\sigma^2 \log K \;\leq\; D_\sigma(\mu) \;\leq\; \sum_{i=1}^{n} m_i,$$

并求其极限。

（3）（4 分）对每个 i，取 $r_{ik} > 0$ 且 $\sum_k r_{ik} = 1$，定义

$$F(r, \mu) = \sum_{i=1}^{n} \sum_{k=1}^{K} r_{ik} \log \frac{\frac{1}{K}\mathcal{N}(x_i \mid \mu_k, \sigma^2 I_d)}{r_{ik}}.$$

可直接使用对数的 Jensen 不等式：若 $a_k > 0$、$r_k > 0$ 且 $\sum_k r_k = 1$，则

$$\log\left(\sum_k r_k a_k\right) \geq \sum_k r_k \log a_k,$$

且所有 a_k 相等时取等号。令 $r^{(t)}$ 是参数 $\mu^{(t)}$ 下的精确责任度，$\mu^{(t+1)}$ 是对应的精确 M 步更新。证明 $\ell_\sigma(\mu) \geq F(r, \mu)$，核验当前点的等号，并写出证明

$$\ell_\sigma(\mu^{(t+1)}) \geq \ell_\sigma(\mu^{(t)})$$

的完整不等式链。

（4）（4 分）本小问改用两个一维高斯分量，方差不再固定或共享。给定任意有限的互异实数 $t_1, \ldots, t_m$，其中整数 $m \geq 2$，考虑

$$p(t; \theta) = \frac{1}{2}\mathcal{N}(t \mid a_1, v_1) + \frac{1}{2}\mathcal{N}(t \mid a_2, v_2), \qquad \theta = (a_1, a_2, v_1, v_2), \quad v_1, v_2 > 0.$$

这里第二个高斯参数 v_j 表示**方差**，一维密度为

$$\mathcal{N}(t \mid a, v) = (2\pi v)^{-1/2} \exp\left(-\frac{(t-a)^2}{2v}\right).$$

构造一族参数 $\theta(\varepsilon)$，使一个分量向 t_1 收缩、另一个分量保持固定的正方差，并证明

$$\sum_{i=1}^{m} \log p(t_i; \theta(\varepsilon)) \longrightarrow +\infty \qquad (\varepsilon \to 0^+).$$

证明须同时控制 t_1 处和其余观测点处的对数密度。

3 自编码器与 NMF：重构与表示的差别 [18 分]

本题三个小问分别给出数据与假设，相互独立。$\|M\|_F^2$ 表示矩阵 M 的全部元素平方和，$\|u\|_2$ 为向量的欧氏范数。

（1）（6 分）设数据矩阵 $X \in \mathbb{R}^{n\times d}$ 的每一行为一个样本，列均值为零，且 $S = X^\top X$ 正定。取编码向量 $a \in \mathbb{R}^d$ 和解码向量 $b \in \mathbb{R}^d$，考虑

$$\widehat{X} = Xab^\top, \qquad L(a,b) = \|X - Xab^\top\|_F^2, \qquad \|b\|_2 = 1.$$

固定 b 时，展开目标并求最优 a；随后求一个最优 b 和最小重构误差，用 S 的最大特征值及对应单位特征向量表示结果。正定指对所有非零 $u \in \mathbb{R}^d$ 都有 $u^\top Su > 0$；注意：最大特征值不一定为单重。

（2）（6 分）设 $X \in \mathbb{R}^{n\times d}$，编码器矩阵 $E \in \mathbb{R}^{d\times r}$、解码器矩阵 $D \in \mathbb{R}^{r\times d}$，其中 $1 \le r < d$，编码与重构分别为

$$Z = XE, \qquad \widehat{X} = ZD.$$

对任意可逆矩阵 $A \in \mathbb{R}^{r\times r}$，定义

$$E' = EA, \qquad D' = A^{-1}D.$$

证明变换后的重构与原重构相同，并写出编码中两点的欧氏距离在变换后的表达式。

再考虑 $n = 3, r = 2$ 时的三个编码点（按行给出）：

$$Z = \begin{bmatrix} -2/3 & -1/3 \\ 4/3 & -1/3 \\ -2/3 & 2/3 \end{bmatrix}.$$

构造一个正对角矩阵 $A = \mathrm{diag}(s_1, s_2)$，其中 $s_1, s_2 > 0$，使 Z 与 ZA 的**最优两簇 K-means 划分不同**；两簇均非空。核验两种表示下的最优划分，允许用三对距离的比较代替列举所有中心。

（3）（6 分）对非负矩阵分解，定义

$$L(W,H) = \|V - WH\|_F^2, \qquad W, H \text{ 的所有元素均非负.}$$

固定 H，考虑乘法更新

$$W^+ = W \odot \frac{VH^\top}{WHH^\top},$$

其中 $\odot$ 和分式分别表示逐元素乘法和逐元素除法。给定

$$V = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad W = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \qquad H = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

计算 W_{12}^+ 以及更新前的 $\partial L/\partial W_{12}$。然后仅把原矩阵的 W_{12} 改为 $\delta > 0$，其他元素和 H 全部不变，求使损失严格下降的全部 δ。

4 PCA、核映射与 SVM：表示如何改变分类 [24 分]

设训练样本为 (x_i, y_i)，$x_i \in \mathbb{R}^d$、$y_i \in \{-1, +1\}$，$i = 1, \ldots, n$，两类均有样本。带截距的硬间隔 SVM 为

$$\min_{w\in\mathbb{R}^d,\ b\in\mathbb{R}} \frac{1}{2}\|w\|_2^2 \quad \text{满足} \quad y_i(w^\top x_i + b) \geq 1 \quad (i = 1, \ldots, n).$$

截距 b 不受惩罚。对非零 w，本题的几何间隔统一指最近训练点到分离超平面的距离；在规范化的最优解处为

$$\gamma = \frac{1}{\|w\|_2}.$$

各小问均重新给出所需表示。

（1）（6 分）设 $1 \leq r \leq d$，$U \in \mathbb{R}^{d\times r}$ 满足 $U^\top U = I_r$，表示为 $z_i = U^\top x_i$。证明在 z_i 上训练权重 $\beta \in \mathbb{R}^r$、截距 b 的硬间隔 SVM，等价于

$$\min_{\substack{w\in\mathrm{col}(U)\\ b\in\mathbb{R}}} \frac{1}{2}\|w\|_2^2 \quad \text{满足} \quad y_i(w^\top x_i + b) \geq 1.$$

这里 $\mathrm{col}(U) = \{U\beta : \beta \in \mathbb{R}^r\}$。写出两个问题的双向参数对应，核对预测、约束和目标值。等价性也应涵盖投影后不可分、两个问题均无可行解的情形。

（2）（6 分）四个等权样本为

i	1	2	3	4
$x_i^\top$	$(10, 1)$	$(-10, 1)$	$(10, -1)$	$(-10, -1)$
y_i	$+1$	$+1$	-1	-1

用 $S = \frac{1}{4}\sum_{i=1}^4 x_i x_i^\top$ 计算第一主成分方向和保留的方差比例。仅保留该一维投影后，证明任意确定性分类函数 $g : \mathbb{R} \to \{-1, +1\}$ 在这四点上的错误率至少为 $1/2$。再求原二维空间的最优 w, b, γ，并证明其最优性。

（3）（6 分）设原始训练集线性可分，$A \in \mathbb{R}^{d\times d}$ 可逆，表示为 $z = A^\top x$。在表示空间中使用权重 $\beta \in \mathbb{R}^d$ 和截距 b，令原空间权重为 $w = A\beta$。将目标 $\frac{1}{2}\|\beta\|_2^2$ 改写为 w 的二次型，并求内积核

$$k_A(x, x') = (A^\top x)^\top (A^\top x').$$

分别将结果用于以下两种 A：

$$\text{（i）}\ A^\top A = AA^\top = I_d; \qquad \text{（ii）}\ A = S^{-1/2},\quad S \text{ 为正定协方差矩阵.}$$

第二种情形中，若

$$S = Q\,\mathrm{diag}(\lambda_1, \ldots, \lambda_d)Q^\top, \quad Q^\top Q = I_d, \quad \lambda_j > 0,$$

则定义

$$S^{-1/2} = Q\,\mathrm{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})Q^\top.$$

对两种情形均写出原空间目标和核。

（4）（6 分）设特征映射 $\phi : \mathbb{R}^d \to \mathbb{R}^q$，其中 q 为正整数，对应核为

$$k(x, x') = \phi(x)^\top \phi(x').$$

假设训练集在该特征空间中线性可分，硬间隔 SVM 的一个最优解为 (v_*, b_*)，其中 $v_* \in \mathbb{R}^q$。对常数 $c > 0$，令

$$k_c(x, x') = c\,k(x, x'), \qquad \phi_c(x) = \sqrt{c}\,\phi(x).$$

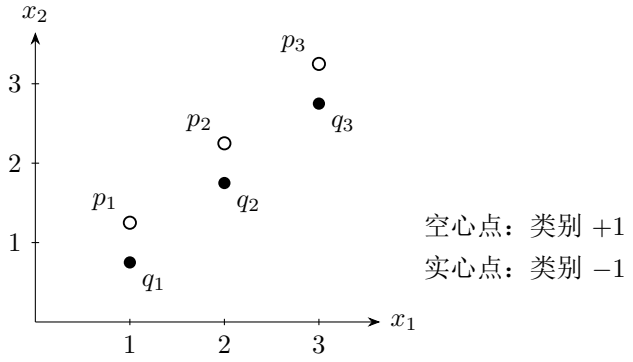
构造新问题的一个最优解 $(v_{c,*}, b_{c,*})$，并通过双向可行解对应证明最优性。求新旧预测分数、最优目标值与几何间隔的关系；利用这些关系构造预测完全相同、但数值间隔严格变大的例子。

5 决策树与线性分类：坐标和复杂度 [18 分]

给定六个等权的二维样本，$i = 1, 2, 3$：

$$p_i = (i, i + 1/4)^\top, \quad y(p_i) = +1; \qquad q_i = (i, i - 1/4)^\top, \quad y(q_i) = -1.$$

允许的决策树为二叉、轴对齐阈值树：每个内部节点选择一个坐标 $j \in \{1, 2\}$ 和阈值 t，按 $x_j \le t$ 与 $x_j > t$ 分支；每个叶节点输出固定的 $+1$ 或 -1。叶节点使用多数类，同票时任选一类。训练错误率为六个样本中误分类的比例。一个内部节点、两个叶节点的树称为树桩。



(1)（4 分）对每个坐标，仅考查相邻不同特征值的中点作为候选阈值，且两个分支均非空。求最优树桩的训练错误率，给出一个达到最优值的坐标、阈值及叶节点预测。说明不存在错误率更低的候选树桩；可以用简表或对有序标签的分析。

(2)（6 分）证明任意零训练误差的上述决策树至少需要六个非空叶节点，并给出一棵达到该下界的树。可使用：同一叶节点的区域是两个坐标区间的笛卡尔积，即一个轴对齐矩形（区间可以无界）。可以用按顺序判断阈值的规则描述树，不强制画树图。

(3)（4 分）改用旋转后的坐标

$$z = Rx, \qquad R = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}.$$

计算六个样本的 z_2，构造一个零训练误差的树桩，写出原坐标中与它对应的线性分类函数。只需保证六个样本上正确，分类边界上的输出可任意规定。

(4)（4 分）回到原坐标，仅比较以下三棵候选树：

- T_1：只有一个叶节点，在全部样本中输出多数类；
- T_2：在根节点按 $x_2 \le 1$ 分裂，左叶输出 -1，右叶输出 $+1$；
- T_6：按 x_2 从小到大的顺序，依次使用阈值 $1, 3/2, 2, 5/2, 3$，每次将最小的剩余样本分离到左叶；最终六个叶节点各含一个样本，输出该样本的标签。

令 $L(T)$ 为叶节点数，$\alpha \ge 0$，代价为

$$C_\alpha(T) = \mathrm{Error}(T) + \alpha L(T).$$

写出三个代价函数，求所有 $\alpha \ge 0$ 下的最优候选树。代价相等时选择叶节点更少的树，须明确分界点属于哪个区间。