LAB3：少量标签能否跨设备识别？

中国科学技术大学

2026 年秋季学期　学生版
截止时间：2026 年 12 月 21 日 06:00

两台设备测量同一批物体时，读数会随设备而变。你的任务是利用少量类别标签和同一物体的成对观测，训练一个能在新设备上识别物体的分类器。你需要回答两个问题：哪些变化来自设备？排除部分设备变化以后，一个类别能否用一个中心描述？

提交与评分

个人完成。将报告 `学号-姓名-LAB3.pdf` 上传至 Blackboard，将单个 `submission.py` 上传至 OJ。只接收这两项材料。建议报告 6–8 页。允许 AI 辅助；注明用途，并给出一次本人能解释的独立核验。

评分项	分值	依据
OJ 代码	30	PCA 8，K-means 单步更新 8，簇到类别映射 8，端到端接口 6。
OJ 性能	20	六个设备与形态条件的平均召回率和最弱组召回率各占 10 分。
报告	50	实现核验 8，基准诊断 12，交叉对照 14，打乱配对 12，复现 4。

环境创建（不计分）

按 LAB0 安装 Miniforge，进入实际保存的 LAB3 根目录。若使用 LAB0 的示例路径，Windows PowerShell 与 macOS Terminal 分别执行下列第一行或第二行。

```
cd $HOME\ALML_public\LABs\LAB3
cd ~/ALML_public/LABs/LAB3
```

在同一个终端执行以下命令，创建独立环境。每次重新打开终端后先激活环境。

```
conda env create -f environment.yml
conda activate ai3002-lab3
python src/run.py env
```

检查 `results/env.json` 中的解释器路径和版本。只编辑 `src/submission.py`；框架在 `src/`，公开数据在 `data/`，各阶段的记录和图保存在 `results/`。

数据与评估协议

每个实例有 3 个类别、64 个连续特征。源设备各测量 600 个物体，其中 150 个物体由两台设备各测量一次。每台设备每类只给出 6 个标签，共 36 条有标签记录。成对观测均无标签。评估物体与训练物体分开生成。

公开文件中的数组	读取方式与用途
`X`, `y`	形状分别为 $(1200, 64)$ 和 $(1200,)$。类别编码为 $0, 1, 2$，未知标签记为 -1。前后各 600 行来自两台源设备。
`pairs`	形状为 $(150, 2)$。每行是 `X` 中同一物体的两个行号，按源设备顺序排列。
`tests`, `truth`	公开验证观测与标签，形状为 $(3, 240, 64)$ 和 $(3, 240)$。每组每类 80 个物体。仅由运行器用于评估、选参及画图。

公开分为三个实例编号，每个编号有两份独立数据。`single` 中每个类别有一种主要形态，`double` 中同一类可以有两种相距较远的形态。每份数据包含三个验证条件：`same` 保持源设备中干扰与类别的相关方向，`neutral` 消除该相关，`reverse` 反转其方向。实例之间的观测坐标系也会改变。

允许使用的信息

每个实例独立拟合。表示学习可访问该实例 `X`、`pairs`；类别赋值可使用已知训练标签。最终设置对所有实例固定。公开验证只用于比较方案，不得用验证观测拟合表示或聚类中心。不得按文件名、形态标识、实例序号或评估设备切换配置。OJ 使用新的物体和坐标系，隐藏观测由私有评分器逐点应用模型；提交内容须为通用 NumPy 计算，不得读取文件、使用外部数据或预训练参数。

模型怎样预测

令 $x \in \mathbb{R}^d$ 为一个样本，训练得到均值 $\mu \in \mathbb{R}^d$、映射矩阵 $P \in \mathbb{R}^{d\times r}$、表示空间的中心 $c_j \in \mathbb{R}^r$ 及其类别 ℓ_j。框架按下式预测；距离并列时取中心行号最小者：

$$z = P^\top (x - \mu), \qquad j^*(x) = \arg\min_j \|z - c_j\|_2^2, \qquad \widehat{y}(x) = \ell_{j^*(x)}.$$

单中心分类器对每类已标注的训练表示取平均。多簇分类器对全部训练表示运行 K-means，再用少量标签给簇赋类。两种分类器均可预测新物体。

任务一 实现与小例核验（报告 8 分）

在 `submission.py` 中完成以下函数。允许 `numpy.linalg.svd` 和特征值分解；PCA、Lloyd 更新和簇标注需使用 NumPy 编写。所有行号从 0 开始。

1. `fit_pca(X, retain)` 返回训练均值和按方差降序排列的正交主轴。取覆盖指定比例的最小维数 r。若中心化后奇异值是 $s_1 \geq \cdots \geq s_m$，判据为

$$\sum_{j=1}^{r} s_j^2 \;\geq\; \texttt{retain} \sum_{j=1}^{m} s_j^2.$$

   输入总方差为正，$0 < \texttt{retain} \leq 1$。新样本必须沿用训练均值与主轴。主轴符号可以改变。

2. `lloyd_step(X, centers)` 返回每行分配给旧中心的整数下标，以及更新后的中心矩阵。距离并列取较小中心下标；没有分到任何训练点的中心保留原位置。

3. `label_clusters(X, centers, y)` 返回每个中心的类别。按上述距离分配已知标签，簇内多数票决定类别；票数相等取较小类号。如果簇中无已知标签，取离该中心最近的已标注训练样本的类别；该距离并列取训练行号较小者。

4. `get_config()` 返回字典，`clusters` 为 2 至 18 间的整数，`representation` 为容纳表示参数的 JSON 字典。`learn_representation(X, pairs, settings)` 返回 (μ, P)，形状为 $(64,)$ 和 $(64, r)$，其中 $1 \leq r \leq 64$。该映射可随训练样本估计，参数选择规则必须固定。

```
python src/run.py check
```

报告证据

用下面的二选一算例手算，再与 `check.json` 逐项核对。若选择 PCA，写出均值与投影矩阵 $PP^\top$；若选择 Lloyd，写出旧分配和新中心。

$$X_{\mathrm{PCA}} = \begin{bmatrix} 3 & 2 \\ 1 & 2 \\ 2 & 2 \end{bmatrix}, \quad \texttt{retain} = 0.9; \qquad X_{\mathrm{Lloyd}} = (0, 2, 8, 10)^\top, \quad C = (0, 8, 30)^\top.$$

再用 Lloyd 算例及标签 $(2, -1, 0, -1)^\top$，将中心行按 $(2, 0, 1)$ 重排。记录重排前后的簇类别，并说明在该例中同一物体的预测是否改变。可引用空簇的新位置或无标注簇的类别，展示一次边界检查。

任务二　普通基准在什么条件下失效？（报告 12 分）

```
python src/run.py baseline
```

比较原始特征和保留 90% 方差的 PCA 表示，二者均使用相同的最近类中心分类器。baseline.json 给出保留维数、逐实例混淆矩阵及六组指标；baseline.png 汇总六组，confusion.png 展示第一个双形态实例。混淆矩阵的行是真实类别，列是预测类别。

报告中列出两种方法的六组召回率。选一个实例，对照同向和反向设备下的混淆矩阵，指出至少一个具体类别由哪些正确预测转成了哪些误判。根据保留维数和分类误差，判断高解释方差在本实验中能否保证识别所需的信息。

任务三　表示和分类器各自解决了什么？（报告 14 分）

先提出一条能用训练数据检验的假设，例如“同一物体的两次读数有哪些方向变化最大”。写出你如何使用配对索引构造表示，以及如何在公开验证集上选择表示参数、簇数。冻结候选后执行：

```
python src/run.py compare
```

框架交叉组合原始 / 改进表示和单中心 / 多簇分类器，输出 compare.json、compare.png。除表中对应因素外，各方法共享样本、已知标签和随机种子。多簇拟合使用 K-means++ 初始化，独立启动 5 次，每次至多 60 次更新，按训练簇内平方和最小选取结果。最终提交采用“改进表示＋多簇分类”。在报告中保留至少两组实际比较过的设置及其公开成绩，说明为何冻结当前设置。不同设置的运行记录可用 --out 分开保存。

报告证据

用一张四行六列的表呈现最终设置的对照。固定分类器，比较表示；再固定表示，比较分类器。至少给出两处逐组的百分点差，并说明结论是否同时适用于两种形态。即使改进方法输给基准，控制变量清楚且证据支持解释，仍可取得相应分析分。

任务四　打乱配对能否推翻自己的解释？（报告 12 分）

先记录事前预测：如果改进来自同一物体的正确配对，破坏配对后，哪一组性能最可能下降？若没有下降，什么原因也能解释先前结果？

```
python src/run.py stress
```

脚本通过固定置换更换每个左端点的右侧伙伴，每个原配对均被破坏，且两侧记录各自的边际分布不变。正确配对与打乱配对分别重新拟合，训练观测、标签、学习算法、超参数和初始化种子固定。输出 `stress.json`、`stress.png`。报告列出两种形态和三种设备上的结果，量化性能的变化，并回到事前预测解释一处支持或削弱它的观测。若结果与预测相反，说明哪项假设值得重查。

任务五　冻结与复现（报告 4 分）

```
python src/run.py final
```

在同一输出目录先运行最终代码的 `compare`。脚本核对源文件摘要、配置，重新拟合并验证六组结果与记录一致，写入 `final.json`。报告末尾给出配置、选择时的取舍、软件版本、运行命令、总时间、AI 使用情况及一项可复核自检。任务一的手算可直接作为自检。

最终性能如何算分

每个隐藏实例、每种设备条件先求三类召回率的平均值。对同一形态和设备条件的实例等权平均，得到六组分数 a_g。令 A 为这六组的算术平均，W 为最小值。隐藏评估共 12 个种子，每个种子各生成一份单形态和双形态数据。性能分计算为

$$h(x;t)=\min\left(1,\max\left(0,\frac{x-1/3}{t-1/3}\right)\right),\qquad S=10h(A;0.945)+10h(W;0.925).$$

当六组平均召回率 $A\geq 94.5\%$ 且最弱组召回率 $W\geq 92.5\%$ 时，性能项得满 20 分。例如，若 $A=96\%$、$W=90\%$，两项分别得 10 分和约 9.58 分，合计约 19.58 分。评分使用未舍入的召回率。训练失败、模型形状不合规或产生非有限值时性能项记零。代码四项按各项通过的检查组比例独立计分。